



Machine Learning Basics



Spring ۲۰۲۶

Instructors: Mohammadreza A. Dehghani, Mostafa Tavassolipour

Arash Taherifard, Amirhossein Aref, Hamidreza Taleai

Final Project —
Phase ۱

معرفی کلی پروژه

در این پروژه، هدف اصلی طراحی یک سیستم یادگیری ماشین برای تحلیل داده‌های صوتی و تشخیص dialect و جنسیت گوینده است. دانشجویان در طول پروژه با یک مسئله‌ی واقعی در حوزه‌ی پردازش گفتار روبه‌رو می‌شوند و باید از مرحله‌ی جمع‌آوری داده تا استخراج ویژگی، طبقه‌بندی، خوشه‌بندی و ارزیابی مدل‌ها را به‌صورت کامل انجام دهند.

در این پروژه، تمرکز صرفاً بر اجرای چند مدل آماده نیست؛ بلکه کیفیت داده، دقت در انتخاب نمونه‌ها، استدلال در مورد روش‌های پیش‌پردازش، انتخاب ویژگی‌های مناسب و تحلیل نتایج اهمیت بسیار زیادی دارد. بنابراین انتظار می‌رود دانشجویان مانند یک پژوهشگر یا مهندس یادگیری ماشین با مسئله برخورد کنند و تصمیم‌های خود را در گزارش به‌صورت دقیق توضیح دهند.

هدف فاز اول

فاز اول به جمع‌آوری و مستندسازی داده‌های صوتی اختصاص دارد. در این مرحله، هر گروه باید مجموعه‌ای از فایل‌های صوتی مناسب برای تشخیص گویش و جنسیت گوینده تهیه کند. کیفیت داده‌های جمع‌آوری‌شده در این فاز، مستقیماً روی عملکرد مدل‌ها در فازهای بعدی اثر می‌گذارد؛ بنابراین انتخاب فایل‌های صوتی باید با دقت انجام شود.

داده‌های جمع‌آوری‌شده توسط گروه‌ها در پایان این فاز توسط تیم آموزشی بررسی، جمع‌بندی و برای ساخت دیتاست خام نهایی پروژه استفاده خواهد شد. در فازهای بعدی، دانشجویان با دیتاست خام نهایی منتشرشده توسط تیم آموزشی کار خواهند کرد.

ساختار گروه‌ها

- هر گروه باید شامل ۳ نفر باشد.

گویش‌های مورد نظر

گویش‌های این پروژه به‌صورت ثابت و به شرح زیر تعیین شده‌اند:

- ترکی
- کردی
- مشهدی
- اصفهانی
- گیلکی

هر گروه موظف است دقیقاً یکی از گویش‌های بالا را انتخاب کند.

انتخاب گویش از طریق نظرسنجی اعلام‌شده در سامانه درس انجام می‌شود.

- برای هر گویش، حداقل ۲ گروه و حداکثر ۳ گروه می‌توانند آن را انتخاب کنند.
- پس از تکمیل ظرفیت هر گویش، امکان انتخاب آن وجود نخواهد داشت.
- گروه‌هایی که یک گویش مشترک را انتخاب می‌کنند، باید از **محتوای متفاوت** مانند فیلم، سریال، برنامه، مصاحبه و منابع مشابه استفاده کنند.
- استفاده از محتوای تکراری بین گروه‌ها مجاز نیست و باعث حذف داده خواهد شد.

منابع پیشنهادی داده

داده‌های صوتی پروژه می‌توانند از فیلم‌ها، سریال‌ها، مستندها، مصاحبه‌ها یا برنامه‌های موجود در Telewebion و سایر منابع عمومی مشابه استخراج شوند. انتخاب منبع باید به گونه‌ای باشد که گفتار گوینده واضح، طبیعی و نماینده‌ی گویش مورد نظر باشد.

استفاده از داده‌هایی که شامل موسیقی پس‌زمینه‌ی شدید، چند گوینده‌ی هم‌زمان، نویز زیاد یا سکوت طولانی هستند توصیه نمی‌شود. چنین داده‌هایی در فازهای بعدی باعث کاهش کیفیت ویژگی‌ها و افت عملکرد مدل‌ها خواهند شد.

وظایف اصلی در فاز اول

در این فاز، هر گروه باید مراحل زیر را انجام دهد:

۱. انتخاب گویش و منابع صوتی مناسب.
۲. استخراج فایل‌های صوتی کوتاه از منابع انتخاب‌شده.
۳. بررسی شنیداری همه‌ی فایل‌ها و حذف نمونه‌های نامناسب.
۴. نام‌گذاری استاندارد فایل‌ها طبق فرمت مشخص‌شده.
۵. ثبت اطلاعات هر فایل در یک فایل متادیتا.
۶. تهیه‌ی یک گزارش کوتاه درباره‌ی نحوه‌ی جمع‌آوری داده.

شرایط فایل‌های صوتی

هر فایل صوتی باید شرایط زیر را داشته باشد:

- مدت زمان هر فایل حدود ۶۰ ثانیه باشد.
- فایل صوتی باید شامل گفتار واضح و قابل فهم باشد.
- فایل نباید دارای سکوت طولانی در ابتدا، وسط یا انتها باشد.
- فایل نباید شامل موسیقی پس‌زمینه‌ی غالب یا نویز شدید باشد.
- ترجیحاً در هر فایل فقط یک گوینده صحبت کند.
- فایل‌ها باید تا حد امکان از نظر جنسیت و کیفیت ضبط متنوع باشند.
- فایل صوتی نباید از وسط یک کلمه یا جمله به شکل نامناسب بریده شود.

تعداد فایل‌ها

هر گروه باید برای گویش انتخاب‌شده:

- بین ۱۵ تا ۲۰ فایل صوتی از گویندگان مرد
- و بین ۱۵ تا ۲۰ فایل صوتی از گویندگان زن

جمع‌آوری کند.

استفاده از چند گوینده مرد و چند گوینده زن برای هر گروه مجاز است، اما شناسه‌ی هر گوینده باید به‌صورت دقیق و ثابت در نام فایل‌ها مشخص شود.

رعایت توازن بین داده‌های مربوط به گویندگان زن (تعداد فایل‌های مرد‌ها و زن‌ها باید یکسان باشد) و مرد الزامی است و در ارزیابی پروژه تاثیرگذار خواهد بود.

فرمت ذخیره‌سازی

تمام فایل‌های صوتی باید با فرمت mp3 ذخیره شوند.

فرمت نام‌گذاری فایل‌ها

برای نظم‌دهی داده‌ها، تمام فایل‌ها باید دقیقاً طبق فرمت زیر نام‌گذاری شوند:

GroupID_Dialect_Gender_SpeakerID_VoiceNumber.mp3

برای مثال:

G03_Gilaki_Female_F01_Voice01.mp3

یا:

G03_Kordi_Male_M02_Voice12.mp3

در نام‌گذاری فایل‌ها باید از مقادیر ثابت زیر استفاده شود:

- Dialect: یکی از مقادیر Gilaki, Isfahani, Mashhadi, Kordi, Torki
- Gender: یکی از مقادیر Male یا Female
- SpeakerID: شناسه‌ی گوینده به‌صورت ثابت برای هر گوینده، مانند M01, M02, F01 یا F02
- VoiceNumber: شماره فایل صوتی به‌صورت دو رقمی، مانند Voice01, Voice02, ...

نام فایل‌ها باید با اطلاعات ثبت‌شده در فایل متادیتا کاملاً یکسان باشد. در صورت عدم تطابق نام فایل و اطلاعات متادیتا، ممکن است داده‌ی مربوطه در ارزیابی پروژه در نظر گرفته نشود.

فایل متادیتا

هر گروه باید یک فایل متادیتا با فرمت csv آماده کند. نام فایل متادیتا باید به‌صورت زیر باشد:

GroupID_metadata.csv

ترتیب ستون‌های فایل متادیتا باید دقیقاً مطابق ترتیب زیر باشد و تغییر در نام یا ترتیب ستون‌ها قابل قبول نیست:

اطلاعاتی مانند گویش، جنسیت، شناسه گوینده، شماره فایل و شناسه گروه از نام فایل استخراج می‌شوند و نیازی به تکرار آن‌ها در فایل متادیتا نیست.

Column Order	Column Name
1	filename
2	source_url
3	start_time
4	end_time
5	duration_seconds
6	speaker_description
7	notes

توضیح ستون‌ها:

- filename: نام دقیق فایل صوتی.
- source_url: لینک منبع فایل صوتی.
- start_time: زمان شروع قطعه صوتی در منبع اصلی.
- end_time: زمان پایان قطعه صوتی در منبع اصلی.
- duration_seconds: مدت زمان فایل بر حسب ثانیه.
- speaker_description: توضیح کوتاه درباره گوینده.
- notes: توضیحات تکمیلی.

گزارش فاز اول

گزارش فاز اول باید کوتاه اما دقیق باشد و شامل موارد زیر شود:

۱. معرفی کوتاه مسئله‌ی تشخیص گویش و جنسیت از داده صوتی.
۲. توضیح منابعی که برای جمع‌آوری داده استفاده شده‌اند.
۳. توضیح معیارهای انتخاب یا حذف نمونه‌های صوتی.
۴. توضیح توزیع داده‌ها از نظر گویش و جنسیت.
۵. اشاره به چالش‌هایی که در جمع‌آوری داده وجود داشته است.
۶. ارائه‌ی جدول خلاصه شامل تعداد نمونه‌ها برای گویش انتخاب‌شده و هر جنسیت.

نکات مهم

- کیفیت داده از تعداد زیاد داده مهم‌تر است.
- همه‌ی فایل‌ها باید قبل از ارسال به‌صورت شنیداری بررسی شوند.
- فایل‌های دارای نویز زیاد، سکوت طولانی یا موسیقی غالب باید حذف شوند.
- استفاده از داده‌های تکراری یا بسیار مشابه توصیه نمی‌شود.
- هرگونه استفاده از منابع باید در گزارش ذکر شود.

نحوه‌ی ارسال

موارد زیر باید ارسال شوند:

- پوشه‌ی شامل تمام فایل‌های صوتی نام‌گذاری شده.
 - فایل متادیتا با فرمت .csv.
 - گزارش فاز اول با فرمت PDF.
- تمام فایل‌ها باید در یک فایل فشرده با فرمت zip قرار داده شوند و در سامانه‌ی اعلام‌شده بارگذاری شوند.

سیاست‌های کلی پروژه

- هرگونه کپی‌برداری مستقیم از گزارش یا داده‌ی گروه‌های دیگر تخلف محسوب می‌شود.
- استفاده از منابع علمی، ابزارهای کمکی و هوش مصنوعی مجاز است، اما متن نهایی گزارش باید توسط خود دانشجویان نوشته و فهمیده شده باشد.
- اگر بخشی از گزارش از منبعی الهام گرفته شده است، باید منبع آن ذکر شود.
- در صورت مشاهده‌ی شباهت غیرعادی بین گزارش‌ها یا داده‌های گروه‌های مختلف، مطابق قوانین آموزشی برخورد خواهد شد.

پشتیبانی و پاسخ به سوالات

در صورت وجود هرگونه سوال یا ابهام در خصوص پروژه، لطفاً از طریق ایمیل با دستیاران آموزشی در ارتباط باشید:

- arashtaherifard@ut.ac.ir
- Amirhosseinaref@ut.ac.ir
- hamidrezatalei@ut.ac.ir