



دانشگاه تهران  
دانشکده مهندسی برق و کامپیوتر

## گزارش فاز سوم

پروژه نهایی درس یادگیری ماشین  
تشخیص گویش و جنسیت از داده‌های صوتی

### گروه ۴

|                           |                  |
|---------------------------|------------------|
| شماره دانشجویی: 810604076 | نیما حسن خلق     |
| شماره دانشجویی: 810803074 | ایلیا جعفری زاده |
| شماره دانشجویی: 810803069 | ایلیا افضلی      |

اساتید  
محمدرضا ابوالقاسمی دهاقانی، مصطفی توسلی پور

بهار ۱۴۰۵

## فهرست مطالب

|    |       |                                                                                         |
|----|-------|-----------------------------------------------------------------------------------------|
| ۳  | ۱     | توضیح کوتاه دیتاست و ویژگی‌های استفاده‌شده                                              |
| ۴  | ۲     | توضیح روش تقسیم داده به <b>Train</b> و <b>Validation</b> پس از کنار گذاشتن تست‌ست رسمی  |
| ۴  | ۱.۲   | روش اول: جستجوی شبکه‌ای با اعتبارسنجی متقاطع (GridSearchCV)                             |
| ۵  | ۲.۲   | روش دوم: تقسیم سفارشی داده‌ها با استفاده از تابع اختصاصی                                |
| ۶  | ۳     | توضیح مراحل آماده‌سازی داده برای مدل‌سازی                                               |
| ۶  | ۱.۳   | PCA                                                                                     |
| ۶  | ۲.۳   | LDA                                                                                     |
| ۶  | ۳.۳   | تحلیل واریانس (ANOVA)                                                                   |
| ۷  | ۴.۳   | بررسی ترکیب‌های مختلف انتخاب ویژگی                                                      |
|    | ۴     | توضیح مدل‌های طبقه‌بندی برای هر دو مسئله‌ی تشخیص گویش و تشخیص جنسیت و دلیل انتخاب آن‌ها |
| ۸  | ۱.۴   | KNN                                                                                     |
| ۸  | ۲.۴   | SVM                                                                                     |
| ۸  | ۳.۴   | Random Forest                                                                           |
| ۹  | ۴.۴   | MLP                                                                                     |
| ۹  | ۵.۴   | مدل نهایی ترکیبی (Stacking Ensemble)                                                    |
| ۹  | ۶.۴   | دلایل انتخاب مدل‌ها                                                                     |
| ۱۰ | ۵     | گزارش و تحلیل معیارهای ارزیابی طبقه‌بندی                                                |
| ۱۵ | ۶     | نمایش و تحلیل <b>Confusion Matrix</b> برای مدل‌ها                                       |
| ۱۵ | ۱.۶   | Gender (ANOVA)                                                                          |
| ۱۶ | ۲.۶   | Dialect (ANOVA)                                                                         |
| ۱۷ | ۳.۶   | Dialect (PCA + LDA)                                                                     |
| ۱۸ | ۴.۶   | Dialect (PCA + LDA + ANOVA)                                                             |
| ۱۹ | ۵.۶   | SVM test-set Evaluation                                                                 |
| ۲۰ | ۶.۶   | Ensemble test-set Evaluation                                                            |
| ۲۱ | ۷     | توضیح مدل‌های خوشه‌بندی گویش و دلیل انتخاب آن‌ها                                        |
| ۲۱ | ۱.۷   | K-Means                                                                                 |
| ۲۱ | ۲.۷   | Gaussian Mixture Model (GMM)                                                            |
| ۲۱ | ۳.۷   | DBSCAN                                                                                  |
| ۲۲ | ۴.۷   | خوشه‌بندی سلسله‌مراتبی (Hierarchical Clustering)                                        |
| ۲۲ | ۵.۷   | مقایسه کلی الگوریتم‌ها                                                                  |
| ۲۳ | ۸     | تحلیل <b>Elbow Method</b> و <b>Silhouette Score</b>                                     |
| ۲۳ | ۱.۸   | تحلیل K-Means                                                                           |
| ۲۳ | ۱.۱.۸ | روش آرنج (Elbow Method)                                                                 |

|    |                                                    |     |
|----|----------------------------------------------------|-----|
| ۲۴ | ۲.۱.۸ تحلیل نتایج سیلوئت                           | ۲۴  |
| ۲۴ | تحلیل GMM — معیارهای AIC و BIC                     | ۲.۸ |
| ۲۵ | داشبورد ارزیابی جامع                               | ۳.۸ |
| ۲۶ | ۹ نمایش دوبعدی داده‌ها با PCA و t-SNE              |     |
| ۲۶ | ۱.۹ نمایش با برجسب‌های واقعی گویش                  |     |
| ۲۶ | ۲.۹ نمایش با تخصیص خوشه‌های K-Means و GMM          |     |
| ۲۶ | ۳.۹ نمایش با تخصیص خوشه‌های DBSCAN و سلسله‌مراتبی  |     |
| ۲۸ | ۴.۹ تحلیل سیلوئت نمونه‌ای (Per-Sample Silhouette)  |     |
| ۲۹ | ۱۰ تحلیل خطا، بیش‌برازش، نشت داده و جمع‌بندی نهایی |     |
| ۲۹ | ۱.۱۰ تحلیل خطا در بخش طبقه‌بندی                    |     |
| ۲۹ | ۱.۱.۱۰ خطاهای تشخیص جنسیت                          |     |
| ۲۹ | ۲.۱.۱۰ خطاهای تشخیص گویش                           |     |
| ۲۹ | ۳.۱.۱۰ خطاهای خوشه‌بندی                            |     |
| ۲۹ | ۲.۱۰ بررسی بیش‌برازش (Overfitting)                 |     |
| ۲۹ | ۱.۲.۱۰ طبقه‌بندی                                   |     |
| ۳۰ | ۲.۲.۱۰ خوشه‌بندی                                   |     |
| ۳۰ | ۳.۱۰ جلوگیری از نشت داده (Data Leakage)            |     |
| ۳۰ | ۴.۱۰ جمع‌بندی نهایی                                |     |
| ۳۰ | ۱.۴.۱۰ چالش‌های اصلی پروژه                         |     |
| ۳۱ | ۲.۴.۱۰ راهکارهای پیشنهادی برای بهبود               |     |

## ۱ توضیح کوتاه دیتاست و ویژگی‌های استفاده‌شده

در این بخش، به‌منظور جلوگیری از پدیده نشت داده (Data Leakage)، نمونه‌های مربوط به تست‌ست رسمی از مجموعه داده ویژگی‌های استخراج‌شده در فاز دوم جدا شد. پس از جداسازی داده‌های تست، شمای کلی مجموعه داده‌ای که برای آموزش (Train) و اعتبارسنجی (Validation) مورد استفاده قرار گرفته است، در جدول‌های ۱ و ۲ خلاصه شده است.

جدول ۱: شمای کلی دیتاست مورد استفاده برای آموزش و اعتبارسنجی

| مقدار     | مشخصه                                                 |
|-----------|-------------------------------------------------------|
| ۳۲۴       | تعداد کل نمونه‌های غیر تست (Total non-test samples)   |
| (۹۹، ۳۲۴) | ابعاد ویژگی‌ها (Features shape)                       |
| ۳۱        | تعداد گروه‌های یکتای گویندگان (Unique speaker groups) |

جدول ۲: توزیع گویش‌ها و جنسیت در مجموعه داده

| توزیع گویش (Dialect) |       | توزیع جنسیت (Gender) |       |
|----------------------|-------|----------------------|-------|
| دسته‌بندی            | تعداد | دسته‌بندی            | تعداد |
| ترکی (Torki)         | ۹۷    | زن (Female)          | ۱۷۰   |
| کردی (Kordi)         | ۸۹    | مرد (Male)           | ۱۵۴   |
| گیلکی (Gilaki)       | ۷۵    |                      |       |
| اصفهان‌ای (Isfahani) | ۴۲    |                      |       |
| مشهدی (Mashhadi)     | ۲۱    |                      |       |

با توجه به اینکه تعداد ویژگی‌های استخراج‌شده از فاز دوم به حدود ۱۰۰ ویژگی می‌رسد، در این گزارش از ذکر تمامی آن‌ها صرف‌نظر شده است. در عوض، تنها مهم‌ترین ویژگی‌هایی که طی فرایند انتخاب ویژگی (Feature Selection) بهترین عملکرد را از خود نشان داده‌اند، مورد بررسی قرار می‌گیرند. فهرست برترین ویژگی‌های انتخاب‌شده برای دو مسئله تشخیص جنسیت و گویش در جدول ۳ ارائه شده است.

جدول ۳: مهم‌ترین ویژگی‌های انتخاب‌شده برای تشخیص جنسیت و گویش

| تشخیص جنسیت<br>(براساس ANOVA F-Score) | تشخیص گویش<br>(براساس بیشترین وزن در LDA) | تشخیص گویش<br>(براساس بیشترین واریانس در PCA) |
|---------------------------------------|-------------------------------------------|-----------------------------------------------|
| mfcc_10_std                           | logmel_5_mean                             | pitch_mean                                    |
| pitch_mean                            | logmel_3_mean                             | logmel_12_mean                                |
| chroma_5_mean                         | logmel_4_mean                             | mfcc_2_mean                                   |
| chroma_12_std                         | logmel_9_mean                             | logmel_10_mean                                |
| mfcc_9_mean                           | logmel_11_mean                            | logmel_13_mean                                |
| sc_3_std                              | –                                         | –                                             |

## ۲ توضیح روش تقسیم داده به Train و Validation پس از کنار گذاشتن تست تست رسمی

به منظور ارزیابی عملکرد مدل‌ها و تنظیم بهینه پارامترها، در این پروژه از دو رویکرد متفاوت برای تقسیم داده‌ها استفاده شده است. در ادامه، روش اول و چالش‌های آماری مرتبط با آن تشریح می‌گردد.

### ۱.۲ روش اول: جستجوی شبکه‌ای با اعتبارسنجی متقاطع (GridSearchCV)

در این رویکرد از الگوریتم GridSearchCV [۱] استفاده شده است. روند کار بدین صورت است که فهرستی از پارامترها و معماری‌های مختلف مدل‌ها به الگوریتم داده می‌شود و این روش با بهره‌گیری از تکنیک اعتبارسنجی K-Fold (که در این آزمایش  $k = 5$  در نظر گرفته شده است)، تمامی ترکیب‌های ممکن را ارزیابی می‌کند تا در نهایت بهترین مدل همراه با بهینه‌ترین (Hyperparameters) مشخص گردد.

با این وجود، همان‌طور که پیش‌تر در جدول توزیع داده‌ها مشاهده شد، مجموعه داده مورد استفاده از منظر دسته‌بندی گویش‌ها کاملاً نامتوازن (Imbalanced) است. یکی از چالش‌های اساسی در این بخش، محدود بودن گویش مشهودی به تنها ۳ گوینده در کل دیتاست بود. این کمبود شدید داده سبب شد که در فرایند تقسیم داده‌ها، در چندین فولد (Fold) هیچ نمونه‌ای از گویش مشهودی (و در مواردی گویش اصفهانی) در مجموعه اعتبارسنجی (Validation Set) حضور نداشته باشد. این مسئله به طور مستقیم موجب افت دقت و تعمیم‌پذیری مدل بر روی گویش مشهودی می‌گردد.

همچنین فولد‌ها به صورتی تقسیم بندی شدند که هر گوینده تنها در یک فولد قرار داشته باشد که نشی بین دیتاست train و validation نداشته باشیم. این کار با اختصاص دادن یک ID یکتا به هر گوینده انجام شد.

خلاصه‌ای از آمار مربوط به توزیع نمونه‌ها در ۵ فولد ارزیابی در جدول ۴ گزارش شده است که به وضوح غیبت برخی گویش‌ها در داده‌های اعتبارسنجی را نشان می‌دهد.

جدول ۴: خلاصه وضعیت توزیع گویش‌ها در فولدهای اعتبارسنجی متقاطع ( $k = 5$ )

| شماره فولد | تعداد گویندگان ارزیابی | وضعیت توزیع گویش‌ها در مجموعه اعتبارسنجی (Validation)           |
|------------|------------------------|-----------------------------------------------------------------|
| فولد ۱     | ۳ گوینده               | گویش‌های مشهودی و اصفهانی به طور کامل غایب هستند (Absent).      |
| فولد ۲     | ۴ گوینده               | گویش‌های مشهودی و اصفهانی به طور کامل غایب هستند.               |
| فولد ۳     | ۹ گوینده               | گویش مشهودی به طور کامل غایب است.                               |
| فولد ۴     | ۸ گوینده               | تمامی گویش‌ها حضور دارند (مشهودی: ۱۳ نمونه، اصفهانی: ۱۷ نمونه). |
| فولد ۵     | ۷ گوینده               | تمامی گویش‌ها حضور دارند (مشهودی: ۸ نمونه، اصفهانی: ۷ نمونه).   |

## ۲.۲ روش دوم: تقسیم سفارشی داده‌ها با استفاده از تابع اختصاصی

در رویکرد دوم، از روش‌های رایج اعتبارسنجی متقاطع (CV) استفاده نگردید؛ در عوض، مجموعه داده‌ها با طراحی و پیاده‌سازی یک تابع سفارشی (Custom Function) به دو بخش آموزش (Train) و اعتبارسنجی (Validation) تقسیم شدند. معیار اصلی در طراحی این تابع بدین صورت بود که از هر گویش موجود، دقیقاً یک گوینده در مجموعه اعتبارسنجی (Validation Set) قرار گیرد تا بدین ترتیب، تعداد نمونه‌های صوتی متعلق به هر گویش تا جای ممکن به یکدیگر نزدیک و متوازن باشد. در مرحله نخست، فرآیند آموزش مدل‌ها بر روی داده‌های حاصل از این تقسیم‌بندی به صورت عادی و بدون اعمال تغییرات جانبی انجام شد. با این حال، به دلیل نامتوازن بودن شدید توزیع گویش‌ها در ساختار کلی داده‌ها، نتایج به دست آمده بسیار ضعیف ارزیابی شد؛ به گونه‌ای که عملکرد مدل از انتخاب تصادفی نیز کمتر بود.

در گام بعدی، به منظور تعدیل فرکانس نمونه‌ها و مقابله با چالش عدم توازن کلاس‌ها، تکنیک افزایش داده SMOTE [۲] مورد استفاده قرار گرفت. در این راستا و به منظور پایبندی دقیق به اصول جلوگیری از نشت داده (Data Leakage)، ابتدا جداسازی مجموعه‌های آموزش و اعتبارسنجی صورت پذیرفت و سپس الگوریتم SMOTE صرفاً بر روی داده‌های آموزش (Train Set) اعمال گردید. با وجود رعایت این ملاحظات فنی، خروجی‌های حاصل از این رویکرد ترکیبی نیز بهبود چشمگیری نیافت و دقت مدل همچنان ضعیف‌تر از حد تفکیک شانس و انتخاب تصادفی باقی ماند.

بنابراین، در بخش‌های بعدی این گزارش تنها به درج نتایج و معیارهای عددی حاصل از این مدل بسنده شده و از تحلیل و تشریح مفصل ساختار آن خودداری می‌گردد. در مقابل، تمرکز اصلی گزارش بر روی مدلی معطوف خواهد بود که دقت و تعمیم‌پذیری بهینه و قابل قبولی را از خود نشان داده است.

## ۳ توضیح مراحل آماده‌سازی داده برای مدل‌سازی

در این مرحله، به‌منظور مقابله با چالش «نفرین ابعاد» (Curse of Dimensionality) و کاهش پیچیدگی محاسباتی مدل‌ها، از روش‌های کاهش ابعاد (Dimension Reduction) و انتخاب ویژگی (Feature Selection) استفاده شده است. بدین منظور، سه الگوریتم PCA، LDA و ANOVA مورد بررسی و استفاده قرار گرفتند که توضیح مختصر و روابط ریاضی آن‌ها به شرح زیر است:

### ۱.۳ PCA

این روش یک الگوریتم بدون نظارت (Unsupervised) است که با تبدیل متغیرهای همبسته به مجموعه‌ای از متغیرهای خطی ناهمبسته به نام مؤلفه‌های اصلی، ابعاد داده را کاهش می‌دهد؛ به‌طوری‌که بیشترین واریانس ممکن از داده‌های اولیه حفظ شود. فرمول ریاضی بهینه‌سازی آن عبارت است از:

$$\max_w w^T \Sigma w \quad \text{to subject} \quad w^T w = 1 \quad (1)$$

که در آن  $\Sigma$  نشان‌دهنده ماتریس کوواریانس داده‌ها است.

### ۲.۳ LDA

این روش یک الگوریتم با نظارت (Supervised) است که هدف آن یافتن ترکیب خطی بهینه‌ای از ویژگی‌هاست که بیشترین تفکیک‌پذیری را میان کلاس‌های مختلف ایجاد کند. این الگوریتم با ماکسیم کردن نسبت پراکندگی بین کلاس‌ها به پراکندگی درون کلاس‌ها عمل می‌کند که به معیار فیشر (Fisher's Criterion) معروف است:

$$J(w) = \frac{w^T S_B w}{w^T S_W w} \quad (2)$$

که در آن  $S_B$  ماتریس پراکندگی بین کلاس‌ها (Between-class variance) و  $S_W$  ماتریس پراکندگی درون کلاس‌ها (Within-class variance) است.

### ۳.۳ تحلیل واریانس (ANOVA)

این روش یک تکنیک آماری برای انتخاب ویژگی است که میزان وابستگی خطی بین ویژگی‌های پیوسته و برچسب‌های گسسته را از طریق آزمون فرضیه بررسی می‌کند. در این روش، ویژگی‌ها بر اساس آماره F (F-statistic) رتبه‌بندی می‌شوند که مخرج آن تغییرات درون‌گروهی و صورت آن تغییرات بین‌گروهی است:

$$F = \frac{MS_{\text{between}}}{MS_{\text{within}}} = \frac{SS_B / (K - 1)}{SS_W / (N - K)} \quad (3)$$

که در آن  $SS_B$  مجموع مربعات بین گروه‌ها،  $SS_W$  مجموع مربعات درون گروه‌ها،  $K$  تعداد کلاس‌ها و  $N$  تعداد کل نمونه‌ها است.

### ۴.۳ بررسی ترکیب‌های مختلف انتخاب ویژگی

برای یافتن بهترین مجموعه از ویژگی‌ها جهت آموزش مدل‌ها، سه رویکرد و ترکیب مختلف ابعادی مورد بررسی قرار گرفت. این سه ترکیب بر اساس نتایج به‌دست‌آمده، به ترتیب صعودی میزان دقت (Accuracy) به صورت زیر رتبه‌بندی می‌شوند:

۱. ANOVA (ضعیف ترین)

۲. PCA + LDA

۳. PCA + LDA + ANOVA (بالاترین دقت)

در بخش‌های بعدی گزارش، به بررسی دقیق میزان دقت هر یک از این روش‌های کاهش ابعاد روی مدل‌ها خواهیم پرداخت. همچنین لازم به ذکر است که خلاصه‌ای از ویژگی‌های برتر انتخاب‌شده بر اساس این معیارها، در بخش اول این گزارش آورده شده است.

## ۴ توضیح مدل‌های طبقه‌بندی برای هر دو مسئله‌ی تشخیص گویش و تشخیص جنسیت و دلیل انتخاب آن‌ها

در این مرحله، عملکرد چهار مدل طبقه‌بندی مختلف به همراه یک مدل ترکیبی مورد بررسی قرار گرفته است. در ادامه، ساختار ریاضی، دلایل انتخاب و هایپرپارامترهای تنظیم شده برای هر یک از این مدل‌ها تشریح می‌شود.

### ۱.۴ KNN

این مدل یک الگوریتم غیرپارامتری و ساده است که نمونه‌های جدید را بر اساس بیشترین شباهت به همسایگان نزدیک خود دسته‌بندی می‌کند. معیار شباهت در این پروژه بر پایه فاصله اقلیدسی بین دو نمونه  $x$  و  $y$  محاسبه می‌شود که رابطه ریاضی آن به شرح زیر است:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (۴)$$

هایپرپارامترهای بررسی شده برای این مدل شامل تعداد همسایه‌ها (`model__n_neighbors`) با مقادیر  $[۳, ۵, ۷, ۹, ۱۱]$  بودند.

### ۲.۴ SVM

این مدل با یافتن یک ابرصفحه (Hyperplane) بهینه، مرز بین کلاس‌ها را به گونه‌ای تعیین می‌کند که حاشیه (Margin) بین داده‌ها بیشترین مقدار ممکن شود. در حالت حاشیه نرم (Soft Margin)، تابع هدف بهینه‌سازی به صورت زیر تعریف می‌شود:

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \quad \text{to subject} \quad y_i(w^T \phi(x_i) + b) \geq 1 - \xi_i \quad (۵)$$

در این پروژه دو نوع کرنل مورد ارزیابی قرار گرفت: کرنل RBF (با مقادیر مختلف پارامترهای  $C$  و  $\gamma$ ) و کرنل چندجمله‌ای (Polynomial) با درجه‌های ۲ و ۳ که به صورت تجربی در فضای LDA+PCA بهترین عملکرد را نشان داد.

### ۳.۴ Random Forest

این مدل یک روش انسمبل مبتنی بر درخت‌های تصمیم متعدد است که با میانگین‌گیری یا رای‌گیری بین درخت‌ها، پایداری مدل را افزایش و خطر بیش‌برازش را کاهش می‌دهد. معیار تقسیم گره‌ها در درخت‌ها شاخص جینی (Gini Impurity) است که فرمول آن عبارت است از:

$$Gini = 1 - \sum_{i=1}^C p_i^2 \quad (۶)$$

هایپرپارامترهای تنظیم شده برای این مدل شامل تعداد درخت‌ها (با مقادیر ۱۰۰، ۲۰۰ و ۳۰۰)، حداکثر عمق درخت (`model__max_depth`) و حداقل نمونه در هر برگ (`model__min_samples_leaf`) بودند.

## ۴.۴ MLP

این مدل یک شبکه عصبی (Feedforward) است که با بهره‌گیری از لایه‌های پنهان و توابع فعال‌سازی غیرخطی، قادر است روابط پیچیده موجود در ویژگی‌های صوتی را استخراج کند. هایپرپارامترهای آزمایش شده برای این شبکه شامل ساختارهای مختلف لایه‌های پنهان (`model_hidden_layer_sizes`) به صورت (۶۴)، (۳۲، ۶۴)، و (۱۲۸، ۶۴) و نرخ یادگیری اولیه (`model_learning_rate_init`) با مقادیر 0.01 و 0.001 بودند.

## ۵.۴ مدل نهایی ترکیبی (Stacking Ensemble)

پس از آموزش مدل‌های فوق و بررسی دقیق ماتریس آشفتگی (Confusion Matrix) دو مدل MLP و SVM، مشخص شد که اگرچه هر دو مدل در تشخیص گویش ترکی عملکرد بسیار خوبی دارند، اما یک تفاوت اساسی در رفتار آن‌ها وجود دارد؛ مدل MLP گویش گیلکی را با دقت بالایی تفکیک می‌کند، در حالی که مدل SVM در تشخیص گویش کردی بسیار موفق‌تر عمل می‌کند. این مشاهده ایده استفاده از معماری پشته‌سازی (Stacking) را ایجاد کرد. در این رویکرد، یک مدل پایانی یا متا (Meta-Model) مانند رگرسیون لجستیک (Logistic Regression) بر روی خروجی‌ها و پیش‌بینی‌های دو مدل MLP و SVM آموزش داده می‌شود. وظیفه این مدل لجستیک، یادگیری نحوه وزن‌دهی و اعتماد به هر یک از مدل‌های پایه به ازای داده‌های مختلف است. تابع لجستیک استفاده شده در این ساختار به صورت زیر تعریف می‌شود:

$$P(y = 1|x) = \frac{1}{1 + e^{-w^T x}} \quad (۷)$$

در نتیجه این ترکیب، مدل نهایی علاوه بر حفظ دقت بالا در گویش ترکی، توانایی بسیار بهتری در تمایز دادن و تفکیک دو گویش گیلکی و کردی از یکدیگر پیدا کرد و بالاترین دقت را در میان تمامی روش‌ها به دست آورد.

## ۶.۴ دلایل انتخاب مدل‌ها

مدل‌های SVM و MLP به عنوان قدرتمندترین مدل‌های طبقه‌بندی بین‌آپشن‌های ارائه شده انتخاب شدند. مدل‌های RF و KNN هم با وجود اینکه پیش‌بینی می‌شد عملکرد ضعیف‌تری نسبت به بقیه مدل‌ها ارائه دهند برای مقایسه عملکردها استفاده شدند. در آخر نیز مدل Logistic Regression برای روش stacking استفاده شد که برای جداسازی داده‌های باینری استفاده می‌شود.

## ۵ گزارش و تحلیل معیارهای ارزیابی طبقه‌بندی

در این بخش، نتایج حاصل از آموزش و ارزیابی مدل‌های مختلف بر روی داده‌ها گزارش شده است. در ابتدا به بررسی معیارهای ارزیابی برای مسئله تشخیص جنسیت می‌پردازیم. نتایج به‌دست‌آمده از اعتبارسنجی متقاطع (Out-of-Fold) برای چهار مدل KNN، SVM، Random Forest و MLP در جدول ۵ خلاصه شده است.

جدول ۵: نتایج ارزیابی مدل‌های طبقه‌بندی برای تشخیص جنسیت

| مدل (Model)   | دقت (Accuracy) | Precision     | Recall        | F1-macro      |
|---------------|----------------|---------------|---------------|---------------|
| KNN           | 0.8117         | 0.8112        | 0.8114        | 0.8113        |
| SVM           | 0.8488         | 0.8489        | 0.8498        | 0.8487        |
| Random Forest | <b>0.9043</b>  | <b>0.9040</b> | <b>0.9042</b> | <b>0.9041</b> |
| MLP           | 0.8395         | 0.8416        | 0.8416        | 0.8395        |

همان‌طور که در جدول ۵ مشاهده می‌شود، مدل Random Forest با دستیابی به امتیاز F1-macro معادل 0.9041، با اختلاف معناداری بهترین عملکرد را در تفکیک جنسیت گویندگان از خود نشان داده است. سایر مدل‌ها نیز با دقت‌هایی در بازه 0.81 تا 0.85 عملکرد قابل قبولی داشته‌اند که این امر نشان‌دهنده کیفیت و مناسب بودن ویژگی‌های استخراج‌شده برای مسئله تشخیص جنسیت است. در ادامه، نتایج اولیه (Baseline) برای مسئله تشخیص گویش با استفاده از روش انتخاب ویژگی SelectKBest مورد بررسی قرار می‌گیرد. این نتایج صرفاً به عنوان یک مبنای مقایسه آورده شده‌اند و همان‌طور که انتظار می‌رفت، عملکردی در حدود ۲۰ درصد (تقریباً معادل انتخاب تصادفی بین ۵ کلاس گویش) دارند.

جدول ۶: نتایج ارزیابی مدل‌های طبقه‌بندی برای تشخیص گویش در حالت پایه (Baseline)

| مدل (Model)    | دقت (Accuracy) | Precision | Recall | F1-macro |
|----------------|----------------|-----------|--------|----------|
| KNN (Baseline) | 0.2037         | 0.2106    | 0.2039 | 0.2042   |
| SVM (Baseline) | 0.2222         | 0.2032    | 0.1905 | 0.1942   |

همان‌طور که در جدول ۶ مشاهده می‌شود، عملکرد مدل‌ها در این حالت بسیار ضعیف و نزدیک به حدس تصادفی است. بررسی دقیق‌تر نشان می‌دهد که مدل SVM در تشخیص گویش مشهودی کاملاً ناکام مانده است. این موضوع به وضوح نشان می‌دهد که استفاده از ویژگی‌های خام یا روش‌های ساده انتخاب ویژگی برای تفکیک گویش‌ها به هیچ وجه کافی نیست و استفاده از رویکردهای پیشرفته‌تر کاهش ابعاد (مانند ترکیب PCA و LDA) کاملاً ضروری است.

در این مرحله، تأثیر تکنیک‌های کاهش ابعاد بر روی مدل‌های تشخیص گویش مورد ارزیابی قرار گرفت. نتایج حاصل از دو رویکرد ترکیبی «LDA + PCA» و ترکیب سه گانه «LDA + PCA + ANOVA» در جدول ۷ مقایسه شده‌اند.

جدول ۷: مقایسه عملکرد مدل‌های تشخیص گویش با استفاده از روش‌های مختلف کاهش ابعاد

| مدل (Model)   | فضای ویژگی    | دقت (Accuracy) | F1-macro      | بهترین پارامترها         |
|---------------|---------------|----------------|---------------|--------------------------|
| KNN           | LDA + PCA     | 0.3519         | 0.3063        | PCA=5, K=7               |
| SVM           | LDA + PCA     | 0.4475         | 0.3365        | PCA=5, Poly(deg=2)       |
| Random Forest | LDA + PCA     | 0.3765         | 0.3059        | PCA=20, Trees=100        |
| MLP           | LDA + PCA     | 0.3765         | 0.3277        | PCA=20, Layer=(64,)      |
| KNN           | LDA+PCA+ANOVA | 0.3395         | 0.3185        | ANOVA=30, PCA=5, K=5     |
| SVM           | LDA+PCA+ANOVA | <b>0.4660</b>  | 0.3475        | ANOVA=20, PCA=5, Poly(2) |
| Random Forest | LDA+PCA+ANOVA | 0.3673         | 0.3155        | ANOVA=30, PCA=10         |
| MLP           | LDA+PCA+ANOVA | 0.3827         | <b>0.3581</b> | ANOVA=10, PCA=5          |

بررسی نتایج نشان می‌دهد که اعمال روش‌های کاهش ابعاد به طور قابل توجهی عملکرد تمامی مدل‌ها را نسبت به حالت پایه بهبود بخشیده است. مدل SVM با کرنل چندجمله‌ای در فضای ترکیبی سه گانه (LDA+PCA+ANOVA) توانست به بالاترین دقت (0.4660) دست یابد. از سوی دیگر، شبکه MLP در همین فضا توانست بهترین تعادل را میان کلاس‌ها ایجاد کرده و بالاترین امتیاز F1-macro (0.3581) را ثبت کند. با این حال، همچنان چالش جدی در تفکیک گویش‌های اقلیت، به ویژه گویش مشهدی که کمترین میزان داده را در اختیار داشت، به وضوح در خروجی مدل‌ها (به خصوص SVM) دیده می‌شود.

در این بخش، نتایج ارزیابی نهایی مدل SVM بر روی مجموعه داده‌های تست (با ۵۵ نمونه) برای هر دو مسئله تشخیص جنسیت و تشخیص گویش آورده شده است. جزئیات تفکیک شده این ارزیابی در جدول‌های ۸ و ۹ قابل مشاهده است.

جدول ۸: گزارش ارزیابی نهایی مدل SVM برای تشخیص جنسیت

| تعداد (Support) | F1-score | Recall | Precision | کلاس (Class)             |
|-----------------|----------|--------|-----------|--------------------------|
| 31              | 0.85     | 0.84   | 0.87      | زن (Female)              |
| 24              | 0.82     | 0.83   | 0.80      | مرد (Male)               |
| <b>0.8364</b>   |          |        |           | دقت کل (Accuracy)        |
| 55              | 0.83     | 0.84   | 0.83      | میانگین کلان (Macro Avg) |

جدول ۹: گزارش ارزیابی نهایی مدل SVM برای تشخیص گویش

| تعداد (Support) | F1-score | Recall | Precision | کلاس (Class)             |
|-----------------|----------|--------|-----------|--------------------------|
| 15              | 0.59     | 0.73   | 0.50      | گیلکی (Gilaki)           |
| 14              | 0.11     | 0.07   | 0.20      | اصفهانی (Isfahani)       |
| 10              | 0.50     | 0.70   | 0.39      | کردی (Kordi)             |
| 5               | 0.00     | 0.00   | 0.00      | مشهدی (Mashhadi)         |
| 11              | 0.80     | 0.73   | 0.89      | ترکی (Torki)             |
| <b>0.4909</b>   |          |        |           | دقت کل (Accuracy)        |
| 55              | 0.40     | 0.45   | 0.40      | میانگین کلان (Macro Avg) |

بررسی نتایج نهایی نشان می‌دهد که مدل SVM در مسئله تشخیص جنسیت عملکردی پایدار و قابل قبول با دقت کل 0.8364 از خود نشان داده است و توانسته تعادل مناسبی در تشخیص هر دو جنسیت برقرار کند. در مقابل، عملکرد این مدل در مسئله تشخیص گویش (با دقت کل 0.4909) به شدت تحت تأثیر نامتوازن بودن داده‌ها (Imbalanced Data) قرار گرفته است. در حالی که مدل توانسته گویش ترکی را با دقت بالایی ( $\text{Precision} = 0.89$ ) تشخیص دهد، اما در تشخیص گویش مشهدی که تنها ۵ نمونه ارزیابی داشته، کاملاً ناکام مانده است. این موضوع بار دیگر محدودیت‌های یادگیری از کلاس‌های اقلیت را در فضای ویژگی‌های صوتی برجسته می‌سازد.

در نهایت، نتایج ارزیابی مدل ترکیبی (Stacking Classifier) که از ترکیب پیش‌بینی‌های دو مدل SVM و MLP بر روی فضای ویژگی سه‌گانه به دست آمده است، در جدول ۱۰ گزارش می‌گردد.

جدول ۱۰: گزارش ارزیابی نهایی مدل ترکیبی (Stacking Classifier) برای تشخیص گویش

| تعداد (Support) | F1-score | Recall | Precision | کلاس (Class)                    |
|-----------------|----------|--------|-----------|---------------------------------|
| 15              | 0.67     | 0.60   | 0.75      | گیلکی (Gilaki)                  |
| 14              | 0.67     | 0.57   | 0.80      | اصفهانی (Isfahani)              |
| 10              | 0.50     | 0.70   | 0.39      | کردی (Kordi)                    |
| 5               | 0.57     | 0.40   | 1.00      | مشهدی (Mashhadi)                |
| 11              | 0.83     | 0.91   | 0.77      | ترکی (Torki)                    |
| <b>0.6545</b>   |          |        |           | <b>دقت کل (Accuracy)</b>        |
| 55              | 0.65     | 0.64   | 0.74      | <b>میانگین کلان (Macro Avg)</b> |

همان‌طور که مشاهده می‌شود، استفاده از رویکرد پشته‌سازی موجب ارتقای چشمگیر عملکرد سیستم شده و دقت کل مدل را از 0.49 (در بهترین مدل پایه) به مقدار 0.6545 افزایش داده است. مهم‌ترین دستاورد این معماری ترکیبی، جبران ضعف مدل‌های پایه در تشخیص کلاس‌های اقلیت است؛ به گونه‌ای که این مدل توانسته در تشخیص گویش مشهدی (که پیش از این امتیاز صفر را ثبت می‌کرد) به معیار Precision کامل (1.00) دست یابد. این نتایج به خوبی نشان می‌دهد که متا مدل (Meta-Model) توانسته است نقاط قوت MLP و SVM را به درستی یاد بگیرد و ترکیب کند.

## گزارش تکمیلی: بررسی رویکرد دوم و تکنیک SMOTE (صرفاً جهت مستندسازی)

همان‌طور که در بخش دوم گزارش (تقسیم سفارشی داده‌ها) توضیح داده شد، یک روش جایگزین برای تقسیم‌بندی داده‌ها مورد آزمایش قرار گرفت که در آن دقیقاً یک گوینده از هر گویش برای اعتبارسنجی انتخاب می‌شد. نتایج این بخش به دلیل افت شدید دقت، در معماری نهایی پروژه مورد استفاده قرار نگرفتند و در این قسمت تنها به دلیل کامل بودن گزارش و مستندسازی روند آزمایش‌ها درج شده‌اند تا نشان‌دهنده بن‌بست بودن این مسیر باشند.

جدول ۱۱ مقایسه عملکرد مدل‌های چهارگانه را روی این تقسیم‌بندی سفارشی، پیش و پس از اعمال تکنیک متوازن‌ساز SMOTE نشان می‌دهد (تمامی مدل‌ها در فضای ویژگی LDA+PCA+ANOVA ارزیابی شده‌اند).

جدول ۱۱: ارزیابی مدل‌ها با استفاده از تقسیم‌بندی سفارشی و تاثیر SMOTE (صرفاً جهت گزارش)


| مدل (Model)   | دقت بدون SMOTE | F1-macro بدون SMOTE | دقت با SMOTE | F1-macro با SMOTE |
|---------------|----------------|---------------------|--------------|-------------------|
| KNN           | 0.22           | 0.15                | 0.18         | 0.12              |
| SVM           | 0.25           | 0.21                | 0.29         | 0.19              |
| Random Forest | 0.20           | 0.14                | 0.18         | 0.11              |
| MLP           | 0.18           | 0.12                | 0.15         | 0.08              |

بررسی این نتایج نشان می‌دهد که نه تنها رویکرد انتخاب یک گوینده خاص باعث افت شدید قدرت تعمیم‌پذیری مدل‌ها شده (عملکردی نزدیک یا حتی بدتر از حدس تصادفی)، بلکه اعمال الگوریتم SMOTE در داخل خط لوله (Pipeline) نیز نتوانسته است این مشکل ساختاری را جبران کند. به جز یک افزایش جزئی در دقت مدل SVM، در سایر موارد استفاده از SMOTE حتی به افت بیشتر معیار F1-macro منجر شده است. به همین دلیل، این رویکرد به طور کامل کنار گذاشته شد و تمرکز پروژه بر روی نتایج بخش‌های قبلی قرار گرفت.

## ۶ نمایش و تحلیل Confusion Matrix برای مدل‌ها


در این بخش، عملکرد جزئی و خطاهای متداول بهترین مدل‌ها در دسته‌بندی کلاس‌های مختلف، از طریق ماتریس آشفتگی (Confusion Matrix) ارزیابی می‌شود.

### ۱.۶ Gender (ANOVA)




این ماتریس‌های آشفتگی مربوط به طبقه‌بندی جنسیت با استفاده از مدل پایه (ANOVA) است که نشان می‌دهد می‌توانیم با ساده‌ترین مدل نیز دقت خوبی در تشخیص جنسیت داشته باشیم.

## ۲.۶ Dialect (ANOVA)



این مدل از دقت مطلوب و کافی برخوردار نیست و بررسی‌ها نشان می‌دهد که عمده‌ترین نقطه ضعف آن، هم‌پوشانی بالا و اشتباه گرفتن دو گویش ترکی و کردی با یکدیگر است.


## ۳.۶ Dialect (PCA + LDA)




در این ارزیابی، بررسی عملکرد مدل SVM نشان می‌دهد که این الگوریتم در تفکیک دو گویش ترکی و کردی از یکدیگر موفق عمل کرده، اما در تشخیص گویش گیلکی دچار ضعف است. در نقطه مقابل، مدل MLP توانایی بالایی در تشخیص صحیح گویش گیلکی از خود نشان داده، در حالی که عملکرد آن در شناسایی گویش کردی بسیار ضعیف ارزیابی می‌شود.

## ۴.۶ Dialect (PCA + LDA + ANOVA)


SVM — Dialect (LDA+PCA+ANOVA, poly+rbf) — OOF Confusion Matrix




KNN — Dialect (LDA+PCA+ANOVA) — OOF Confusion Matrix



MLP — Dialect (LDA+PCA+ANOVA) — OOF Confusion Matrix





Random Forest — Dialect (LDA+PCA+ANOVA) — OOF Confusion Matrix




تحلیل نتایج این بخش کاملاً مشابه با مشاهدات ارائه شده در بخش ۴.۶ است؛ با این تفاوت که در اینجا دقت کلی مدل‌ها با بهبود نسبی همراه بوده است.

## ۵.۶ SVM test-set Evaluation



پیش از به کارگیری روش‌های ترکیبی (Ensemble)، مدل پایه در تشخیص گویش‌های گیلکی و ترکی عملکرد قابل قبولی داشته است؛ با این حال، مدل در عمل توانایی شناسایی گویش مشهدی را ندارد. عملکرد مدل در خصوص دو گویش دیگر نیز در سطح متوسط ارزیابی می‌شود. همچنین جنسیت‌ها به خوبی تفکیک شده‌اند.

## ۶.۶ Ensemble test-set Evaluation



این معماری که به عنوان مدل نهایی پروژه انتخاب شده است، توانسته گویش‌های مختلف را با دقت قابل قبولی تفکیک کند. همان‌طور که انتظار می‌رفت، بالاترین میزان دقت مربوط به گویش ترکی است، چرا که این دسته بیشترین سهم از داده‌های آموزشی را به خود اختصاص داده است. نکته حائز اهمیت دیگر این است که علیرغم کمبود شدید داده در کلاس اقلیت (گویش مشهدی)، دقت تشخیص مدل در این گویش نیز با بهبود چشمگیری همراه بوده است.

## ۷ توضیح مدل‌های خوشه‌بندی گویش و دلیل انتخاب آن‌ها

در بخش دوم این پروژه، هدف بررسی آن است که آیا نمونه‌های صوتی بدون استفاده از برجسب‌ها، به‌صورت طبیعی بر اساس گویش از یکدیگر تفکیک می‌شوند یا خیر. برای این منظور، چهار الگوریتم خوشه‌بندی بدون نظارت (Unsupervised Clustering) مورد بررسی و مقایسه قرار گرفتند. تمامی الگوریتم‌ها بر روی داده‌های آموزش (۲۶۹ نمونه با ۹۹ ویژگی) که با StandardScaler نرمال‌سازی شده بودند، اجرا شدند.

### ۱.۷ K-Means

الگوریتم K-Means یکی از ساده‌ترین و پرکاربردترین روش‌های خوشه‌بندی است که با تقسیم داده‌ها به  $k$  خوشه از طریق کمینه‌سازی مجموع مربعات فاصله‌های درون خوشه‌ای (Inertia) عمل می‌کند. تابع هدف این الگوریتم به صورت زیر تعریف می‌شود:

$$J = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2 \quad (۸)$$

که در آن  $C_i$  مجموعه نقاط متعلق به خوشه  $i$  و  $\mu_i$  مرکز خوشه است. در این پروژه، مقادیر  $k$  از ۲ تا ۱۱ بررسی شدند و  $k = 5$  (برابر با تعداد واقعی گویش‌ها) به عنوان مقدار نهایی انتخاب گردید. دلیل انتخاب: سادگی پیاده‌سازی، سرعت بالای اجرا و مناسب بودن به عنوان مبنای مقایسه (Baseline) برای سایر الگوریتم‌ها.

### ۲.۷ Gaussian Mixture Model (GMM)

مدل آمیخته گاوسی یک روش خوشه‌بندی نرم (Soft Clustering) است که هر خوشه را به صورت یک توزیع گاوسی مدل‌سازی می‌کند. برخلاف K-Means که هر نمونه را به یک خوشه اختصاص می‌دهد، GMM احتمال تعلق هر نمونه به تمامی خوشه‌ها را محاسبه می‌کند:

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x | \mu_k, \Sigma_k) \quad (۹)$$

که در آن  $\pi_k$  وزن خوشه  $k$ ،  $\mu_k$  میانگین و  $\Sigma_k$  ماتریس کوواریانس آن خوشه است. تعداد مؤلفه‌ها از ۲ تا ۱۱ بررسی شد و بر اساس معیار BIC، مقدار  $n = 5$  انتخاب گردید. دلیل انتخاب: توانایی مدل‌سازی خوشه‌های بیضوی و نامتقارن، و ارائه احتمال تعلق به جای تخصیص قطعی.

### ۳.۷ DBSCAN

الگوریتم DBSCAN یک روش خوشه‌بندی مبتنی بر چگالی (Density-Based) است که نیازی به تعیین تعداد خوشه‌ها از قبل ندارد. این الگوریتم نقاط در مناطق کم‌تراکم را به عنوان نویز (Noise) با برجسب -۱ مشخص می‌کند. دو پارامتر کلیدی آن عبارتند از:

- eps: شعاع همسایگی — تعیین‌کننده حداکثر فاصله بین دو نمونه برای قرارگیری در یک خوشه

•  $\min\_samples$ : حداقل تعداد نقاط مورد نیاز برای تشکیل یک ناحیه متراکم در این پروژه، مقدار  $\epsilon$  از نمودار فاصله  $k$ -نزدیک‌ترین همسایه ( $k$ -distance plot) استخراج و جستجوی شبکه‌ای بر روی بازه‌ای از مقادیر  $\epsilon$  و  $\min\_samples$  انجام شد. بهترین تنظیمات بر اساس بالاترین NMI انتخاب گردید. دلیل انتخاب: توانایی کشف خوشه‌های با اشکال دلخواه و شناسایی نقاط پرت، بدون نیاز به تعیین تعداد خوشه‌ها.

## ۴.۷ خوشه‌بندی سلسله‌مراتبی (Hierarchical Clustering)

این روش با ساختن یک درخت دندروگرام (Dendrogram) از پایین به بالا (Agglomerative) عمل می‌کند. سه استراتژی پیوند (Linkage) مورد مقایسه قرار گرفتند:

- Ward: کمینه‌سازی افزایش واریانس درون خوشه‌ای هنگام ادغام
- Complete: استفاده از بیشترین فاصله بین نقاط دو خوشه
- Average: استفاده از میانگین فاصله‌ها بین تمامی جفت نقاط دو خوشه

نتایج نشان داد که روش Ward با NMI برابر 0.2900 بهترین عملکرد را در میان استراتژی‌های پیوند داشته است. دلیل انتخاب: ارائه بینش بصری از ساختار سلسله‌مراتبی داده‌ها از طریق دندروگرام و عدم نیاز به فرض شکل خاص برای خوشه‌ها.

## ۵.۷ مقایسه کلی الگوریتم‌ها

جدول ۱۲ خلاصه‌ای از عملکرد چهار الگوریتم خوشه‌بندی را بر اساس سه معیار اصلی نشان می‌دهد.

جدول ۱۲: مقایسه عملکرد الگوریتم‌های خوشه‌بندی

| الگوریتم               | $\uparrow$ Silhouette | $\uparrow$ NMI | $\uparrow$ ARI |
|------------------------|-----------------------|----------------|----------------|
| K-Means                | 0.1724                | 0.3029         | 0.1561         |
| GMM                    | 0.1554                | 0.3048         | 0.1679         |
| خوشه‌بندی سلسله‌مراتبی | 0.1700                | 0.2900         | 0.1376         |
| DBSCAN                 | <b>0.1983</b>         | <b>0.5176</b>  | <b>0.1773</b>  |

همان‌طور که در جدول ۱۲ مشاهده می‌شود، الگوریتم DBSCAN با NMI معادل 0.5176 (معیار اصلی مسابقه خوشه‌بندی) بهترین عملکرد را در تطابق خوشه‌ها با گویش‌های واقعی از خود نشان داده و به عنوان مدل نهایی خوشه‌بندی انتخاب شده است. الگوریتم‌های K-Means و GMM عملکرد نزدیک به هم ( $\Delta NMI = 0.002$ ) داشته‌اند که نشان‌دهنده پایداری نتایج است. با این حال، خالص بودن خوشه‌های DBSCAN (خلوص 0.974) در مقایسه با سایر الگوریتم‌ها (حدود 0.5 تا 0.6) بسیار چشمگیر است، اگرچه این موفقیت با هزینه تعداد بالای خوشه‌ها (18 خوشه) و نرخ نویز 23.4% همراه بوده است.

## ۸ تحلیل Elbow Method و Silhouette Score

برای تعیین تعداد بهینه خوشه‌ها، از دو معیار کلاسیک استفاده شده است: روش آرنج (Elbow Method) و امتیاز سیلوئت (Silhouette Score).


### ۱.۸ تحلیل K-Means

#### ۱.۱.۸ روش آرنج (Elbow Method)

در این روش، مقدار اینرسی (Inertia) — یعنی مجموع مربعات فاصله‌های هر نقطه تا مرکز خوشه‌اش — به ازای مقادیر مختلف  $k$  محاسبه شده و نقطه‌ای که شیب منحنی به طور ناگهانی تغییر می‌کند (نقطه آرنج) به عنوان  $k$  بهینه انتخاب می‌گردد. نتایج محاسبات برای  $k = 2$  تا 11 در جدول ۱۳ آمده است.

جدول ۱۳: مقادیر اینرسی و سیلوئت برای مقادیر مختلف  $k$  در K-Means

| $k$ | اینرسی (Inertia) | امتیاز سیلوئت (Silhouette) |
|-----|------------------|----------------------------|
| ۲   | 22222.9          | 0.1674                     |
| ۳   | 19916.3          | 0.1480                     |
| ۴   | 18304.2          | 0.1645                     |
| ۵   | 17092.7          | 0.1724                     |
| ۶   | 15992.7          | 0.1689                     |
| ۷   | 14997.3          | 0.1862                     |
| ۸   | 14244.6          | 0.1940                     |
| ۹   | 13812.0          | 0.1894                     |
| ۱۰  | 12837.8          | 0.2125                     |
| ۱۱  | 12164.6          | 0.2238                     |



شکل ۱: نمودار روش آرنج و امتیاز سیلوئت برای الگوریتم K-Means

همان‌طور که در شکل ۱ مشاهده می‌شود، منحنی اینرسی کاهش یکنواخت و نسبتاً هموار دارد و نقطه آرنج مشخص و تیزی دیده نمی‌شود. این رفتار نشان‌دهنده آن است که خوشه‌های طبیعی در فضای ویژگی صوتی دارای مرزهای واضحی نیستند. با این حال، یک تغییر ملایم در شیب در حدود

$k = 5$  قابل مشاهده است. از طرف دیگر، منحنی سیلوئت نیز در  $k = 5$  یک قله محلی نشان می‌دهد (0.1724) و پس از آن افت موقتی در  $k = 6$  دیده می‌شود. با توجه به مطابقت  $k = 5$  با تعداد واقعی گویش‌ها، این مقدار به عنوان تعداد بهینه خوشه‌ها انتخاب شد.

### ۲.۱.۸ تحلیل نتایج سیلوئت

امتیاز سیلوئت (Silhouette Score) معیاری بین -1 تا +1 است که کیفیت خوشه‌بندی را اندازه‌گیری می‌کند. فرمول محاسبه آن برای هر نمونه  $i$  عبارت است از:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \quad (10)$$

که در آن  $a(i)$  میانگین فاصله نمونه  $i$  تا سایر اعضای همان خوشه و  $b(i)$  میانگین فاصله آن تا نزدیک‌ترین خوشه مجاور است. مقادیر نزدیک به +1 نشان‌دهنده تفکیک خوب خوشه‌ها و مقادیر منفی نشان‌دهنده تخصیص اشتباه نمونه‌ها هستند.


امتیاز سیلوئت نهایی K-Means با  $k = 5$  برابر 0.1724 به دست آمد که مقداری نسبتاً پایین ارزیابی می‌شود. این نتیجه حاکی از آن است که خوشه‌ها هم‌پوشانی قابل توجهی دارند و مرزهای بین گویش‌ها در فضای ویژگی‌های صوتی به خوبی تفکیک نشده‌اند.

## ۲.۸ تحلیل GMM — معیارهای BIC و AIC

برای مدل آمیخته گاوسی، علاوه بر سیلوئت، از دو معیار اطلاعاتی بیزی (BIC) و آکائیکه (AIC) نیز برای انتخاب تعداد بهینه مؤلفه‌ها استفاده شده است:

● BIC (معیار اطلاعاتی بیزی): مدل‌های ساده‌تر را ترجیح می‌دهد؛ کمترین مقدار BIC در  $n = 5$  با مقدار 9890.5 مشاهده شد.

● AIC (معیار اطلاعاتی آکائیکه): پیچیدگی مدل را کمتر جریمه می‌کند؛ مقادیر آن همچنان کاهش یافته‌اند.




شکل ۲: نمودارهای BIC، AIC و سیلوئت برای مدل GMM

شکل ۲ نشان می‌دهد که معیار BIC در  $n = 5$  به حداقل خود رسیده و سپس افزایش یافته است، که این موضوع تأیید می‌کند 5 مؤلفه بهینه‌ترین مدل از نظر تعادل بین پیچیدگی و برازش است.

### ۳.۸ داشبورد ارزیابی جامع

به منظور ارائه تصویر کلی از عملکرد تمامی الگوریتم‌ها، یک داشبورد ارزیابی جامع (Evaluation Dashboard) طراحی شده است که شش معیار کلیدی را به صورت بصری مقایسه می‌کند: NMI، سیلوئت، ARI، خلوص خوشه (Purity)، توازن خوشه‌ها (Balance) و نرخ نویز.



شکل ۳: داشبورد ارزیابی جامع الگوریتم‌های خوشه‌بندی

نتایج کلیدی داشبورد:


- DBSCAN از نظر NMI (0.518) و خلوص (0.974) برتری آشکاری دارد.
- K-Means و GMM عملکرد بسیار مشابهی دارند ( $\Delta NMI = 0.002$ ) که نشان‌دهنده پایداری نتایج است.
- سیلوئت تمامی الگوریتم‌ها پایین (حدود 0.15 تا 0.20) است که بازتاب هم‌پوشانی بالای ویژگی‌های صوتی بین گویش‌ها در این فضا می‌باشد.
- نرخ نویز DBSCAN (23.4%) در سطح متوسط ارزیابی شده و تعداد بالای خوشه‌ها (18) حاکی از آن است که برخی زیرگروه‌های کوچک‌تر در داده‌ها وجود دارند.

## ۹ نمایش دوبعدی داده‌ها با PCA و t-SNE

به‌منظور درک بصری ساختار داده‌ها و کیفیت خوشه‌بندی، فضای ویژگی ۹۹ بعدی به دو بعد تقلیل داده شده است. برای این منظور از دو روش مکمل استفاده شده است:

- **PCA** (تحلیل مؤلفه‌های اصلی): یک روش خطی و سریع که ساختار واریانس سراسری (Global Variance) داده‌ها را حفظ می‌کند. دو مؤلفه اول 36.5% از واریانس کل داده‌ها را توضیح داده‌اند.
- **t-SNE** (جاسازی تصادفی همسایگی توزیع شده t): یک روش غیرخطی که ساختار محلی (Local Structure) و خوشه‌ای داده‌ها را آشکار می‌سازد. پارامتر perplexity برابر ۳۰ و تعداد تکرارها (iterations) برابر ۱۰۰۰ تنظیم شده است.

### ۱.۹ نمایش با برجسب‌های واقعی گویش



شکل ۴: تصویرسازی دوبعدی داده‌ها با رنگ‌بندی بر اساس برجسب واقعی گویش‌ها (PCA و t-SNE)


شکل ۴ نشان می‌دهد که در نمایش PCA، گویش‌ها هم‌پوشانی زیادی با یکدیگر دارند و مرز واضحی بین آن‌ها مشاهده نمی‌شود. این رفتار با پایین بودن واریانس توضیح داده شده (36.5%) سازگار است. در مقابل، t-SNE توانسته تا حدودی گروه‌بندی‌های محلی را آشکار سازد؛ به‌ویژه نمونه‌های گویش ترکی تمایل به تجمع در ناحیه‌ای مشخص دارند، هرچند هم‌پوشانی بین سایر گویش‌ها (به‌ویژه گیلکی، کردی و اصفهانی) همچنان قابل مشاهده است.

### ۲.۹ نمایش با تخصیص خوشه‌های K-Means و GMM


شکل ۵ مقایسه بصری خوشه‌بندی K-Means و GMM را نشان می‌دهد. هر دو الگوریتم الگوی تخصیص مشابهی ایجاد کرده‌اند که با مقادیر نزدیک NMI آن‌ها (0.303 و 0.305) سازگار است. خوشه‌ها به صورت تقریباً کروی و با هم‌پوشانی قابل توجه دیده می‌شوند.

### ۳.۹ نمایش با تخصیص خوشه‌های DBSCAN و سلسله‌مراتبی

شکل ۶ تفاوت رفتاری DBSCAN و خوشه‌بندی سلسله‌مراتبی را به‌خوبی نمایش می‌دهد. DBSCAN با ایجاد ۱۸ خوشه ریزدانه‌تر (Fine-Grained) و حذف نقاط نویزی، توانسته مناطق متراکم را بهتر




شکل ۵: تصویرسازی دوبعدی با رنگ‌بندی خوشه‌های K-Means و GMM



شکل ۶: تصویرسازی دوبعدی با رنگ‌بندی خوشه‌های DBSCAN و سلسله‌مراتبی

شناسایی کند. در مقابل، خوشه‌بندی سلسله‌مراتبی (با روش Ward) خوشه‌هایی مشابه K-Means ولی با توازن کمتری ایجاد کرده است.

## ۴.۹ تحلیل سیلوئت نمونه‌ای (Per-Sample Silhouette)



شکل ۷: نمودار سیلوئت نمونه‌ای برای بهترین الگوریتم (DBSCAN)

شکل ۷ نمودار سیلوئت نمونه‌ای را برای الگوریتم DBSCAN (بهترین مدل از نظر NMI) نمایش می‌دهد. در این نمودار:

- میله‌هایی که به سمت راست امتداد دارند نشان‌دهنده نمونه‌هایی هستند که به خوبی از خوشه‌های مجاور تفکیک شده‌اند.
- میله‌هایی با مقادیر منفی (سمت چپ) حاکی از تخصیص نادرست احتمالی آن نمونه‌ها به خوشه فعلی هستند.
- خط قرمز چین‌دار نشان‌دهنده میانگین کلی امتیاز سیلوئت است.

## ۱۰ تحلیل خطا، بیش‌برازش، نشت داده و جمع‌بندی نهایی

### ۱.۱۰ تحلیل خطا در بخش طبقه‌بندی

#### ۱.۱.۱۰ خطاهای تشخیص جنسیت

مدل نهایی تشخیص جنسیت (Random Forest) با دقت 90.4% عملکرد بسیار مناسبی داشته و خطاهای آن عمدتاً ناشی از هم‌پوشانی ویژگی‌های صوتی بین برخی گویندگان زن و مرد است. دقت بالا و تعادل مناسب معیارهای Precision و Recall نشان می‌دهد که مدل در هر دو جنس عملکرد متوازنی دارد.

#### ۲.۱.۱۰ خطاهای تشخیص گویش

تحلیل ماتریس‌های آشفتگی مدل‌های گویش نشان‌دهنده چند الگوی خطای متداول است:

۱. ناتوانی در تشخیص گویش مشهدی: مدل پایه SVM در تشخیص گویش مشهدی کاملاً ناکام ماند ( $F1=0.00$ ). این مشکل با تنها ۲۱ نمونه آموزشی (و ۳ گوینده) ارتباط مستقیم دارد.
۲. اشتباه گرفتن گویش‌های کردی و گیلکی: مدل MLP تمایل به اشتباه گرفتن کردی با سایر گویش‌ها دارد، در حالی که SVM در تشخیص گیلکی ضعیف‌تر عمل می‌کند.
۳. تفکیک‌پذیری بالای گویش ترکی: گویش ترکی در تمامی مدل‌ها با بالاترین دقت شناسایی شده ( $Precision=0.89$  در SVM)، که می‌تواند ناشی از تفاوت‌های زبانی بنیادی‌تر (ریشه آلتایی در مقابل ایرانی) باشد.

#### ۳.۱.۱۰ خطاهای خوشه‌بندی

تحلیل ترکیب خوشه‌ها در K-Means و GMM نشان می‌دهد که:

- خوشه‌ها عمدتاً ترکیبی از چند گویش هستند (خلوص 0.53 تا 0.60)
- گویش مشهدی عمدتاً با گویش کردی در یک خوشه قرار گرفته است
- الگوریتم DBSCAN با ایجاد خوشه‌های ریزتر توانسته خلوص بسیار بالاتری (0.974) ایجاد کند

### ۲.۱۰ بررسی بیش‌برازش (Overfitting)

#### ۱.۲.۱۰ طبقه‌بندی

برای جلوگیری از بیش‌برازش در مدل‌های طبقه‌بندی، از روش‌های زیر استفاده شده است:

- اعتبارسنجی متقاطع ۵- فولدی مبتنی بر گوینده (Speaker-Based K-Fold CV): تضمین می‌کند که نمونه‌های هر گوینده فقط در یک فولد حضور داشته باشند.
- تنظیم هایپرپارامترها از طریق GridSearchCV
- استفاده از PCA و LDA برای کاهش ابعاد و جلوگیری از یادگیری ویژگی‌های نویزی

مقایسه دقت مدل Stacking در اعتبارسنجی متقاطع (Out-of-Fold) و روی داده تست رسمی (0.6545) نشان می‌دهد که مدل در حد قابل قبولی تعمیم‌پذیر است و اختلاف عملکرد بین دو مجموعه، حاکی از بیش‌برازش شدید نیست.

## ۲.۲.۱۰ خوشه‌بندی

مفهوم بیش‌برازش در خوشه‌بندی بدون نظارت متفاوت از طبقه‌بندی است. در اینجا، ریسک اصلی ایجاد تعداد بیش از حد خوشه‌هاست (Over-segmentation) که دقیقاً در مورد DBSCAN (با ۱۸ خوشه در مقابل ۵ گویش واقعی) مشاهده شد. با این حال، NMI بالای این الگوریتم نشان می‌دهد که این خوشه‌های ریز، زیرگروه‌های معنادار درون هر گویش را بازتاب می‌دهند.

## ۳.۱۰ جلوگیری از نشت داده (Data Leakage)

- در تمامی مراحل این پروژه، اصول سخت‌گیرانه‌ای برای جلوگیری از نشت داده رعایت شده است:
۱. جداسازی اولیه تست‌ست رسمی: نمونه‌های تست رسمی (۵۵ نمونه) قبل از هرگونه پردازش از مجموعه داده جدا شده و تا مرحله ارزیابی نهایی مورد استفاده قرار نگرفتند.
  ۲. تقسیم مبتنی بر گوینده: با اختصاص یک شناسه یکتا (Unique ID) به هر گوینده، تضمین شد که نمونه‌های صوتی یک گوینده به طور همزمان در مجموعه آموزش و اعتبارسنجی حضور نداشته باشند.
  ۳. اعمال SMOTE صرفاً بر داده آموزش: در رویکردهایی که از SMOTE استفاده شد، تولید نمونه‌های مصنوعی تنها بر روی داده‌های آموزش و پس از جداسازی اعتبارسنجی انجام گرفت.
  ۴. نرمال‌سازی جداگانه: StandardScaler تنها بر روی داده‌های آموزش برازش شده و سپس بر مجموعه اعتبارسنجی و تست اعمال گردید.
  ۵. خوشه‌بندی بر داده آموزش: الگوریتم‌های خوشه‌بندی صرفاً بر روی بخش آموزش اجرا شدند.

## ۴.۱۰ جمع‌بندی نهایی

خلاصه نتایج طبقه‌بندی:

- تشخیص جنسیت: دقت 90.4% (Random Forest) — عملکرد بسیار مناسب
- تشخیص گویش: دقت 65.5% (Stacking Classifier) — بهبود 33% نسبت به مدل پایه
- مدل ترکیبی SVM+MLP توانست ضعف‌های فردی هر مدل را جبران کند

خلاصه نتایج خوشه‌بندی:

- بهترین الگوریتم: DBSCAN با  $NMI = 0.5176$
- خلوص خوشه‌های DBSCAN: 0.974 (بسیار بالا)
- سیلوئت کلی: حدود 0.17 تا 0.20 (هم‌پوشانی بین خوشه‌ها)
- $k = 5$  (تعداد واقعی گویش‌ها) از طریق BIC و تغییر شیب اینرسی تأیید شد

## ۱.۴.۱۰ چالش‌های اصلی پروژه

۱. نامتوازنی شدید داده‌ها: از ۹۷ نمونه ترکی تا ۲۱ نمونه مشهدی، نسبت تقریباً ۵:۱ بود.
۲. تعداد محدود گویندگان: تنها ۳۱ گوینده یکتا در مجموعه آموزش، که تنوع آکوستیکی را محدود می‌کرد.
۳. هم‌پوشانی ویژگی‌های صوتی: سیلوئت پایین ( $\approx 0.17$ ) نشان‌دهنده مرزهای نامشخص بین ویژگی‌های صوتی گویش‌های مختلف (به‌ویژه گویش‌های هم‌خانواده ایرانی) است.
۴. حجم کم داده: ۳۲۴ نمونه آموزشی برای یک مسئله ۵ کلاسه با ۹۹ ویژگی، یک نسبت نمونه‌به‌ویژگی

بسیار پایین ( $\approx 3.3$ ) ایجاد می‌کند.

#### ۲.۴.۱۰ راهکارهای پیشنهادی برای بهبود

- جمع‌آوری داده بیشتر، به‌ویژه برای گویش‌های اقلیت (مشهدی و اصفهانی)
- استفاده از تکنیک‌های افزایش داده صوتی (Audio Data Augmentation) مانند Time Stretching و Pitch Shifting
- بهره‌گیری از مدل‌های یادگیری عمیق مانند CNN یا Transformer بر روی طیف‌نگاره‌های Mel
- آزمایش روش‌های یادگیری نمایش (Representation Learning) مانند Autoencoders پیش از خوشه‌بندی

## مراجع

---

- Scikit-learn developers, “sklearn.model\_selection.GridSearchCV”. [Online]. Available: [۱]  
[https://scikit-learn.org/stable/modules/generated/sklearn.model\\_selection.GridSearchCV.html](https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html)
- Microsoft, “SMOTE - Azure Machine Learning”. [Online]. Available: <https://learn.microsoft.com/en-us/azure/machine-learning/component-reference/smote?view=azureml-api-2> [۲]
- Scikit-learn developers, “sklearn.cluster.KMeans”. [Online]. Available: <https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html> [۳]
- Scikit-learn developers, “sklearn.mixture.GaussianMixture”. [Online]. Available: <https://scikit-learn.org/stable/modules/generated/sklearn.mixture.GaussianMixture.html> [۴]
- Scikit-learn developers, “sklearn.cluster.DBSCAN”. [Online]. Available: <https://scikit-learn.org/stable/modules/generated/sklearn.cluster.DBSCAN.html> [۵]
- Scikit-learn developers, “sklearn.metrics.silhouette\_score”. [Online]. Available: [https://scikit-learn.org/stable/modules/generated/sklearn.metrics.silhouette\\_score.html](https://scikit-learn.org/stable/modules/generated/sklearn.metrics.silhouette_score.html) [۶]
- L. van der Maaten and G. Hinton, “Visualizing Data using t-SNE”, Journal of Machine Learning Research, vol. 9, pp. 2579–2605, 2008. [۷]